

Trabajo Práctico Integrador – Módulo R

Maestría en Econometría – Universidad Torcuato Di Tella

Docente: Ian Evangelos Bounos – Año 2026

Alumno: Sebastián Uria Minaberrigaray

Introducción y resumen ejecutivo

El objetivo del trabajo fue explorar las capacidades del modelo ARIMA (*AutoRegressive Integrated Moving Average*) para estimar y pronosticar series de tiempo de alta volatilidad, en este caso el Índice de Precios al Consumidor (IPC) elaborado por el INDEC.

Luego de pre procesar la base de datos para su análisis, se experimentó con una serie de especificaciones de modelos ARIMA y SARIMA, con el objetivo de mostrar cómo los valores extremos o *outliers* dificultan la predicción de este tipo de series de tiempo. Así, se ajustó un modelo a la totalidad de los datos; se realizaron dos comparaciones con *backtesting* en dos recortes distintos de la serie de tiempo; y se intentó realizar un pronóstico de los valores del índice a lo largo de los próximos meses hasta finales de 2027.

Los resultados demuestran que el modelo ARIMA/SARIMA tiene el potencial de identificar tendencias en series de tiempo, pero que la alta volatilidad que presenta un índice de precios en contextos de inflación elevada presenta serios obstáculos para la calibración del modelo. Cuando se excluyen los valores extremos, el modelo puede ajustarse relativamente bien a los datos, pero la naturaleza del fenómeno inflacionario hace necesario incorporar variables exógenas de difícil medición, como los ciclos electorales, el tipo de cambio, la confianza en el gobierno, o incluso *shocks* externos, que por el momento caen fuera de los métodos cubiertos en la materia.

Parte 1 – Elección del dataset y de la técnica de análisis econométrico

1.1 El dataset

Se utilizó para el análisis [la base de datos más reciente del IPC](#) publicado por el INDEC, *i.e.* del 10 de septiembre de 2026. La misma es un *dataframe* que cubre desde diciembre de 2016 hasta agosto de 2026 con frecuencia mensual. Aunque sería deseable trabajar con el índice de años anteriores, estos deben considerarse con reservas debido a la emergencia estadística, y por lo tanto hemos decidido excluirlos del análisis. Aun así, contamos con 117 períodos, un tamaño bastante razonable para realizar un análisis econométrico.

La elección de la base de datos está sobradamente justificada, ya que la inflación ha sido una problemática central en la política y la economía argentinas de los últimos sesenta años como mínimo, y con particular intensidad en la última década. Los datos recabados por el INDEC son los más confiables para evaluar este fenómeno. Asimismo, la inflación

está motivada por las expectativas sobre el mercado y sobre las decisiones de política económica del gobierno, por lo que pronosticar el comportamiento de la inflación reviste particular importancia.


1.2. La técnica de análisis de datos

Por tratarse de una serie de tiempo, utilizaremos un método ARIMA para estimar la serie. La teoría económica demuestra que la inflación tiene un fuerte componente estacional; no obstante, la volatilidad que caracteriza a nuestra economía introduce complejidad en esta estacionalidad, por lo que solo se estimó la serie con un modelo SARIMA en un corte temporal que excluía valores extremos. Por no contar con una serie de tiempo disponible para una variable interviniente, no se implementó un modelo ARIMAX, aunque entendemos que sería interesante explorar las capacidades estimativas de un modelo semejante.

Parte 2 – Análisis exploratorio de datos

La base de datos incluye el dato del índice general y por cada apertura comercial, dividido por regiones (Noreste, Noroeste, GBA, Pampeana, y Patagonia); no se incluyó una medida del IPC global, y también se incluyen otros datos que no son relevantes para nuestro foco de estudio.


Teniendo esto en cuenta, comenzamos por convertir las etiquetas de período a un formato utilizable en R, y a continuación filtrar la base por nivel general en la región Gran Buenos Aires. Ya que deseamos estudiar el comportamiento de la inflación, podemos quedarnos con la variación mensual del índice –una variable *string*– y transformamos la base a una serie de tiempo para poder trabajar con ella. Al tratarse de la variación del índice, el primer valor es nulo, por lo que lo removemos de nuestra muestra. A continuación se presenta un gráfico exploratorio de los datos:




Se optó por incluir, en líneas punteadas, las fechas de las elecciones parlamentarias y generales durante el período abarcado, a sabiendas de que las expectativas políticas han sido importantes históricamente en el comportamiento de la inflación en la Argentina. Salta rápidamente a la vista que, aunque el grueso de los datos se encuentra por debajo del 5% mensual, a partir de 2022 se produce un movimiento al alza que culmina en un pico inflacionario de 25% luego de las elecciones generales de 2023, donde el oficialismo recibió una derrota considerable. A su vez, el nuevo gobierno propició una devaluación contundente que desplomó el índice en los meses siguientes.

Estos movimientos representan valores muy extremos que obstaculizan la aplicación de métodos econométricos sencillos. No podemos excluir estos valores de nuestro análisis porque constituyen un elemento esencial del fenómeno de interés; de todas formas, contamos con suficientes períodos previos como para correr un modelo antes del pico inflacionario de 2023-2024.

Antes de implementar el modelo ARIMA sobre toda la serie de tiempo, podemos correr funciones de autocorrelación (ACF) y de autocorrelación parcial (PACF) para explorar la estructura de los datos:



La caída lenta y escalonada de la ACF es evidencia de que estamos trabajando con una serie no estacionaria, donde el valor del índice en un mes depende considerablemente de los meses anteriores, por lo que podemos concluir que es necesario diferenciar la serie una vez para poder modelarla:




Como podemos apreciar, con una diferencia la serie empieza a mostrar elementos de estacionariedad: luego del primer rezago, la ACF cae precipitadamente y se queda dentro del umbral, excepto por los rezagos 3 y 5, lo cual evidencia una reversión de la inflación hacia los meses siguientes. Esto se condice con el “comportamiento de serrucho” que presenta el IPC, donde la subida de un mes suele estar seguida por un valor menor. También podemos confirmar la estacionalidad mediante una comparación de tests de Dickey-Fuller Aumentados (ADF): mientras que en la serie en niveles el p valor es de 0,24, con una diferencia el mismo coeficiente se vuelve significativo al 1%, evidenciando


estacionariedad. Estas pruebas nos permiten saber que el modelo que correspondería estimar para toda la serie es uno con una diferencia.

Parte 3 – Aplicación de la técnica e interpretación

Al correr la función *auto.arima* se estima un ARIMA(0,1,0), básicamente un *random walk* o paseo aleatorio. Debido a que los datos presentan volatilidad, el modelo se limita a predecir que el siguiente valor será igual al valor del período anterior, concentrándose solamente en esa primera diferencia.




Observando los residuos encontramos una cola derecha pesada movida por valores extremadamente altos, así como algunos rezagos con autocorrelación significativa. Evidentemente, los *outliers* de fines de 2023 y principios de 2024 son obstáculos para estimar un modelo que capte la estacionalidad del resto de la serie. Podemos ver el impacto de este período en la diferencia entre el MAE (1,13) y el RMSE (1,91), movida por los valores extremos. Además, al ser meramente un *random walk* no nos sirve para pronosticar los valores de la inflación, como podemos apreciar intentando un backtest de los meses posteriores al pico inflacionario. Este modelo no hace más que pronosticar una constante que no replica la tendencia decreciente de los datos observados:




Convencidos de que la volatilidad imposibilita estimar un modelo sencillo como ARIMA, procedemos a la estimación de un modelo utilizando los períodos anteriores al pico inflacionario: desde el inicio de la serie hasta mediados de 2023, antes de las elecciones generales. Al correr la función *auto.arima* obtenemos un modelo SARIMA(0,1,2)(1,0,0)[12], esto es, uno de primera diferencia que incorpora los errores de dos rezagos y compara el valor de este mes con el del mismo mes del año anterior, incorporando así estacionalidad. Los residuos tienen una mejor distribución y la función de autocorrelación se mantiene entre las bandas en todos los rezagos.

Podemos comparar este SARIMA con el ARIMA(0,1,0) anterior aplicado al mismo período reducido, y vemos que el primero supera al segundo en varias métricas, incluido un mejor ajuste reflejado en un menor AIC (213,9 vs. 229,7) y un mayor p valor del test de Ljung-Box, indicando que los residuos del modelo estacional no tienen autocorrelación (0,39 vs. < 0,1%).




Utilizando este modelo especificado con los datos anteriores al pico inflacionario, podemos realizar un *backtesting*: ¿cuánto puede ajustarse la predicción de este modelo a esos valores extremos, así como a las variaciones del índice que le siguieron? La respuesta es, obviamente, muy poco: la escalada de la inflación es tan abrupta y con valores tan fuera de serie que la diferencia entre el valor predicho y el observado se dispara. Si comparamos el error absoluto medio y la raíz del error cuadrático medio en el entrenamiento frente al *holdout*: el MAE aumenta de 0,77 a 4,64 y el RMSE de 0,97 a 5,51, un aumento del error de aproximadamente seis veces fuera de la muestra. Es evidente que no se puede estimar semejante salto solamente con los datos de esta serie. Por el contrario, cabe destacar que todos los valores desde el segundo trimestre de 2024, más normales, cayeron dentro de las bandas del 95% del pronóstico.

Backtesting ARIMA: proyección IPC vs. valores reales




Ante la falla de estos modelos, optamos por un enfoque más limitado. Es difícil predecir un fenómeno económico complejo y volátil tan hacia futuro; ¿será más fácil hacerlo a corto plazo, digamos, mes a mes? Eso es lo que intentamos con el siguiente modelo, que iterativamente pronostica el próximo valor de la variación del IPC en base a los últimos meses. Presentamos un gráfico que parte justo antes del pico inflacionario y llega hasta el valor más reciente:




Como cabía esperar, vemos que el modelo puede ajustarse mucho mejor a los datos observados una vez estos adquieren cierta estabilidad; por el contrario, el modelo tiene dificultades para anticiparse a la suba pronunciada del índice, incluso estimando una nueva alza a principios de 2024; una especie de rebote inflacionario que no incorpora el cambio radical de política cambiaria y fiscal del nuevo gobierno.

Finalmente, podemos intentar un pronóstico de la variación del índice en los próximos meses, cuya precisión no puede ser evaluada en este momento por obvias razones, pero resulta interesante dado el objeto de estudio. Esto se logró aplicando la función *forecast*, que no implementó un modelo ARIMA sino un modelo ETS (o Error, Tendencia y Estacionalidad) de suavizado exponencial con estacional multiplicativa –cuyo análisis particular cae fuera del alcance de este trabajo.

Variación IPC y proyección hasta 2027



Residuals from ETS(M,N,M)



En azul se aprecia el pronóstico de la variación del IPC hasta 2028. Este modelo predice una relativa estabilidad del índice, que no parece capaz de consolidarse más cerca del valor 0 que en los últimos meses; esto podría tener consecuencias electorales para el oficialismo, que enfrenta una apuesta por la reelección el año próximo, como se aprecia por la línea punteada. Si observamos el test de Ljung-Box encontramos un p valor muy alto (0,4812), que prueba fuertemente la falta de autocorrelación de los residuos, más aún que en SARIMA (0,39). Cabe destacar que el intervalo de confianza del *forecast* incluye varios

picos en el período, los mayores siendo justo antes y después de las elecciones generales de 2027, lo cual se condice tanto con la teoría económica como con los valores anteriores en la serie de tiempo; el tiempo nos permitirá saber si este modelo se ajustó a los datos, o si la volatilidad argentina será, una vez más, imposible de predecir.